码士集团
www.mashibing.com

今晚8:05分正式开始

工业级的多Agent项目开发方案

① 什么是Agent？
② 单Agent和多Agent的区别是什么？
③ Supervisor架构的多智能体。
④ Swarm架构的多智能体。
⑤ 多Agent之前的交接（handoffs）怎么解决?
⑥ 大模型开发工程师的就业
⑦ 大模型开发的简历怎么写？

讲师：肖斌

码士集团

码士集团
www.mashibing.com

从AIGC到AI Agent

特性	AIGC (如 ChatGPT)	AI Agent (如 Manus, Operator)
核心能力	内容生成	任务规划与自主执行
交互模式	被动响应，依赖**提示词**	主动规划，自主决策
输出结果	建议、方案、内容（需人工后续处理）	**可交付的最终成果**（如已发送的邮件、整理好的报表）
与外界交互	有限，主要通过文本	强大，可通过工具调用操作现实世界系统

2025年是“Agent元年”！从“思考”到“行动”的范式跃迁

什么是 Agent(智能体)

智能体由四个部分组成：大型语言模型（LLM）、一组可供其使用的工具，以及一个提供指令的提示（prompt）和Tool Executor执行器。

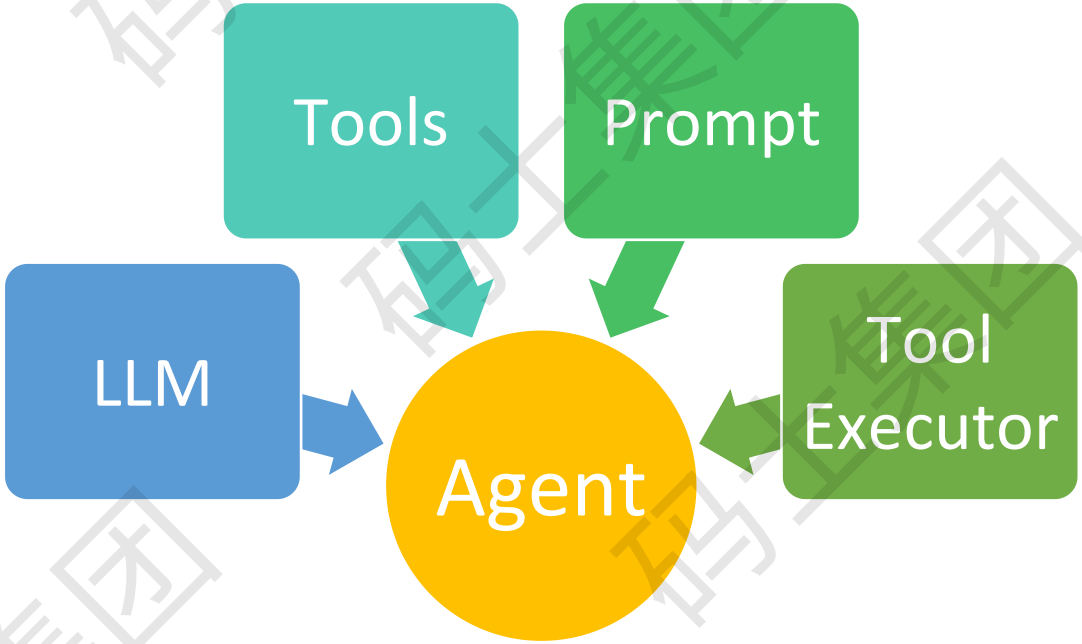

Agent是怎么工作的？

LLM 在一个循环中运行。在每次迭代中，它选择一个要调用的工具，提供输入，接收结果（一次观察），并利用该观察来指导下一步行动。这个循环会一直持续，直到满足停止条件——通常是当智能体收集到足够的信息来回应用户时。

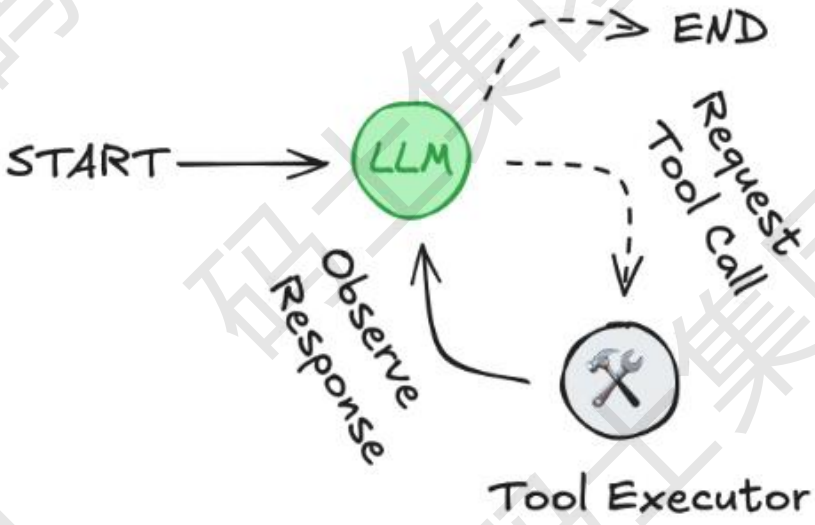

智能体循环：LLM 选择工具并使用其输出来完成用户请求。

码士集团
www.mashibing.com

Agent是怎么工作的？

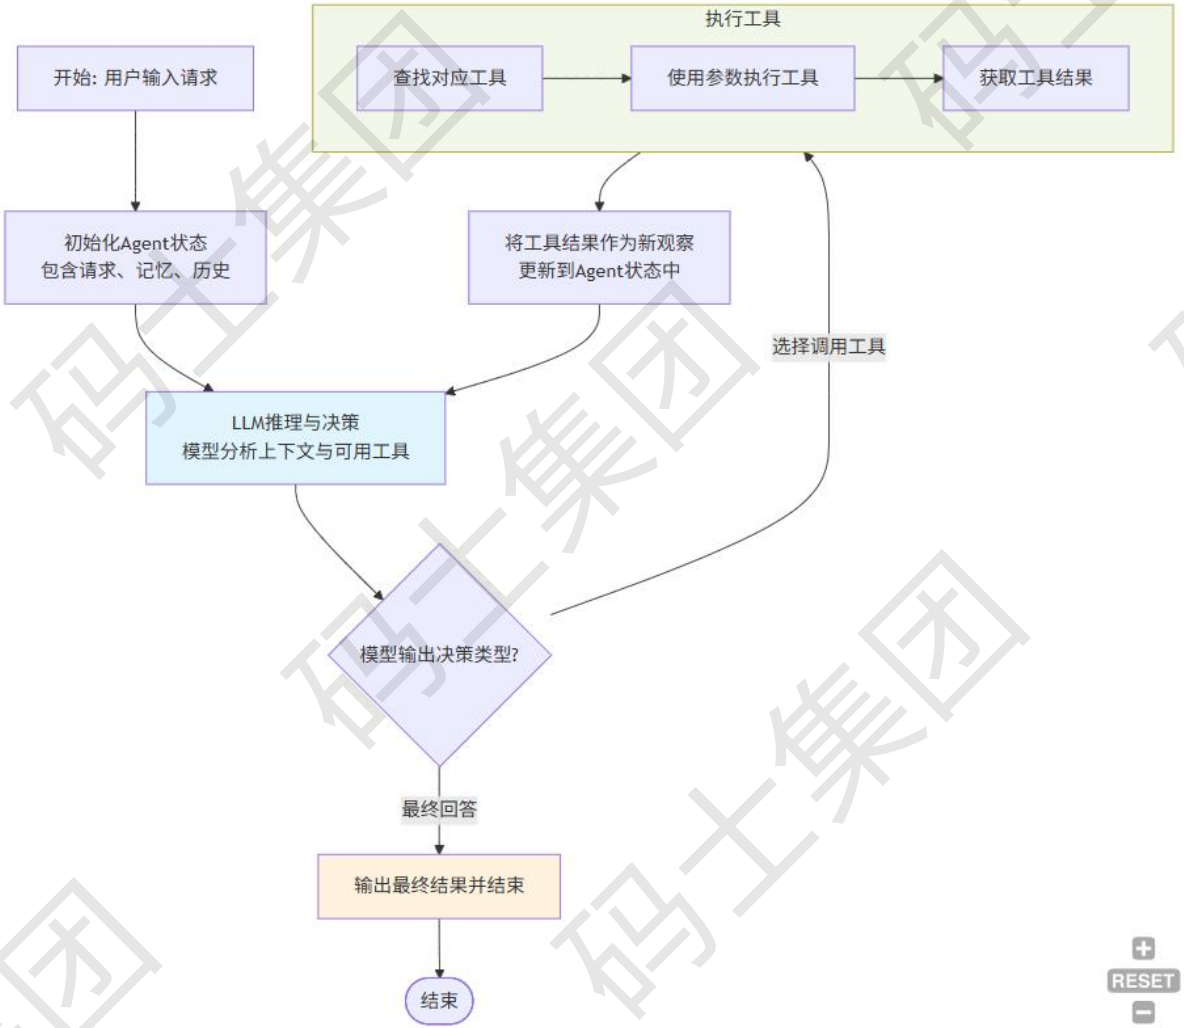

码士集团

码士集团
www.mashibing.com

Agent是怎么工作的？

这个过程通常遵循一种名为 **ReAct (Reason + Act)** 的范式。以下是其工作流程：

步骤 1: 接收输入与构建上下文

Agent接收到用户的请求（例如："上海今天天气怎么样？然后用摄氏度告诉我。"）。执行器会将此请求与之前的对话历史（短期记忆）和任何相关长期记忆组合，形成当前的"上下文"。

步骤 2: LLM 推理与决策

执行器将这个完整的上下文输入给LLM。LLM会根据提示词的指引进行思考。提示词通常会要求模型以特定的格式（如JSON或一段标记清晰的文本）输出它的"想法"和"下一步行动"。

- **Reason (思考)**：模型会先进行内部推理。

  > *"用户想知道上海的天气，并且要求用摄氏度表示。我自己没有实时天气数据，所以我需要一个工具来获取这些信息。可用的工具里有一个叫`get_weather`的工具，它可以查询天气。"*

- **Act (行动)**：然后，模型会根据思考结果，决定一个行动。这个行动要么是**最终回答**，要么是**调用一个工具**。

  > "我应该调用`get_weather`工具，参数是location='上海'。"

工业级的Agent应该掌握什么？

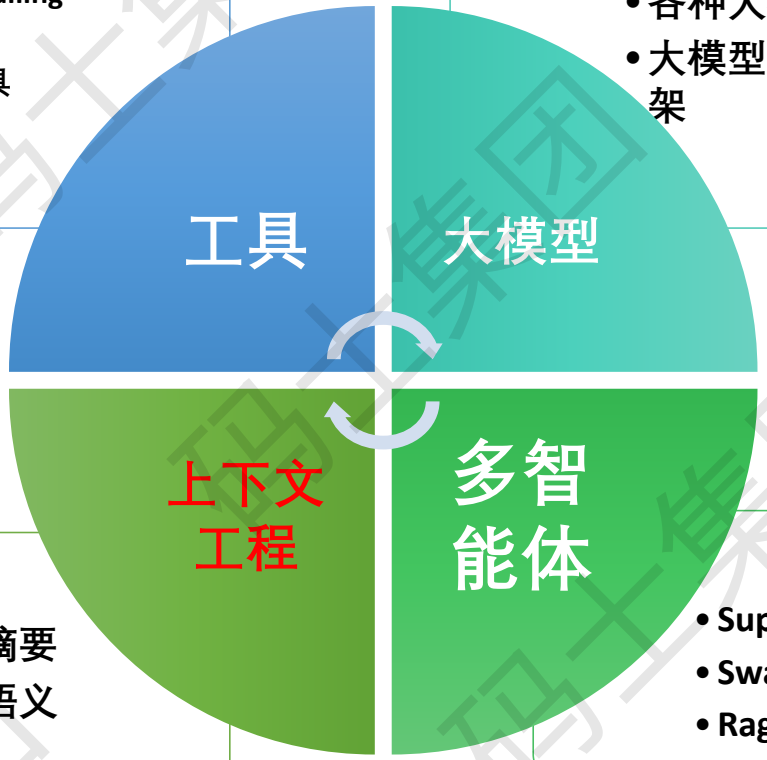

- Function Calling
- MCP 协议
- 自定义工具
- 人工介入

- 各种大模型
- 大模型的推理框架

- 上下文摘要
- 上下文语义检索

- Supervisor架构
- Swarm架构
- Ragas评估

码士集团 www.mashibing.com

大模型的种类	特点	常用大模型
通用语音模型	通用能力强，文本推理，文本生成，深度思考等	DeepSeek，Qwen3，kimi-k2，GPT-4.5, Claude 3系列，等等
多模态模型	多模态支持（文本/图像/音频/视频），跨媒体理解能力强	GPT-4o，Qwen2.5-VL， Qwen2.5-Omni，GLM-4.5V等
文本嵌入模型	将文本转换成计算机能理解的数值向量，对文本进行降维处理。	BGE系列（small, base, large），OpenAI Embedding，Qwen3-Embedding等
多模态嵌入模型	将文本、图像、音频、视频等不同模态的数据向量化，同一个向量空间中。	GME-Qwen2-VL，openai-CLIP，Chinese-CLIP等
多模态解析模型	负责解析复杂结构的的数据	Dolphin，Dots.OCR，MonkeyOCR，Unstructured等等
垂直领域大模型	专注于某一个领域的复杂问题，如蛋白质结构预测	DeepMind-AlphaFold，360安全大模型，讯飞星火 4.0（医疗）等

码士集团

码士集团
www.mashibing.com

大模型推理框架

推理框架名称	所属团队	核心特点
vLLM	加州大学伯克利分校	高效管理KV缓存，显存利用率可达95%以上；支持张量并行和流水线并行。
SGLang	伯克利团队	利用Radix树高效管理和复用KV缓存前缀，尤其擅长多轮对话；结构化输出，零开销批处理；缓存感知负载均衡
Transformers 库	Hugging Face	提供从模型加载、微调到推理的全流程；灵活的API和训练接口，支持模型范围最广。
LMDeploy	上海人工智能实验室	量化部署工具链，针对华为昇腾等国产芯片优化）、多模态融合支持。
TensorRT-LLM	NVIDIA	深度链路优化，预编译优化，支持FP8/INT4等多种量化方案，内核级优化（针对Transformers模块的深度CUDA优化

MCP+Agent

MCP（Model Context Protocol，模型上下文协议），2024年11月底，由 Anthropic 推出的一种开放标准，旨在统一大型语言模型（LLM）与外部数据源和工具之间的通信协议。

Function Calling是AI模型调用函数的机制，MCP是一个标准协议，使AI模型与API无缝交互，而AI Agent是一个自主运行的智能系统，利用Function Calling和MCP来分析和执行任务，实现特定目标。

码士集团
www.mashibing.com

MCP+Agent

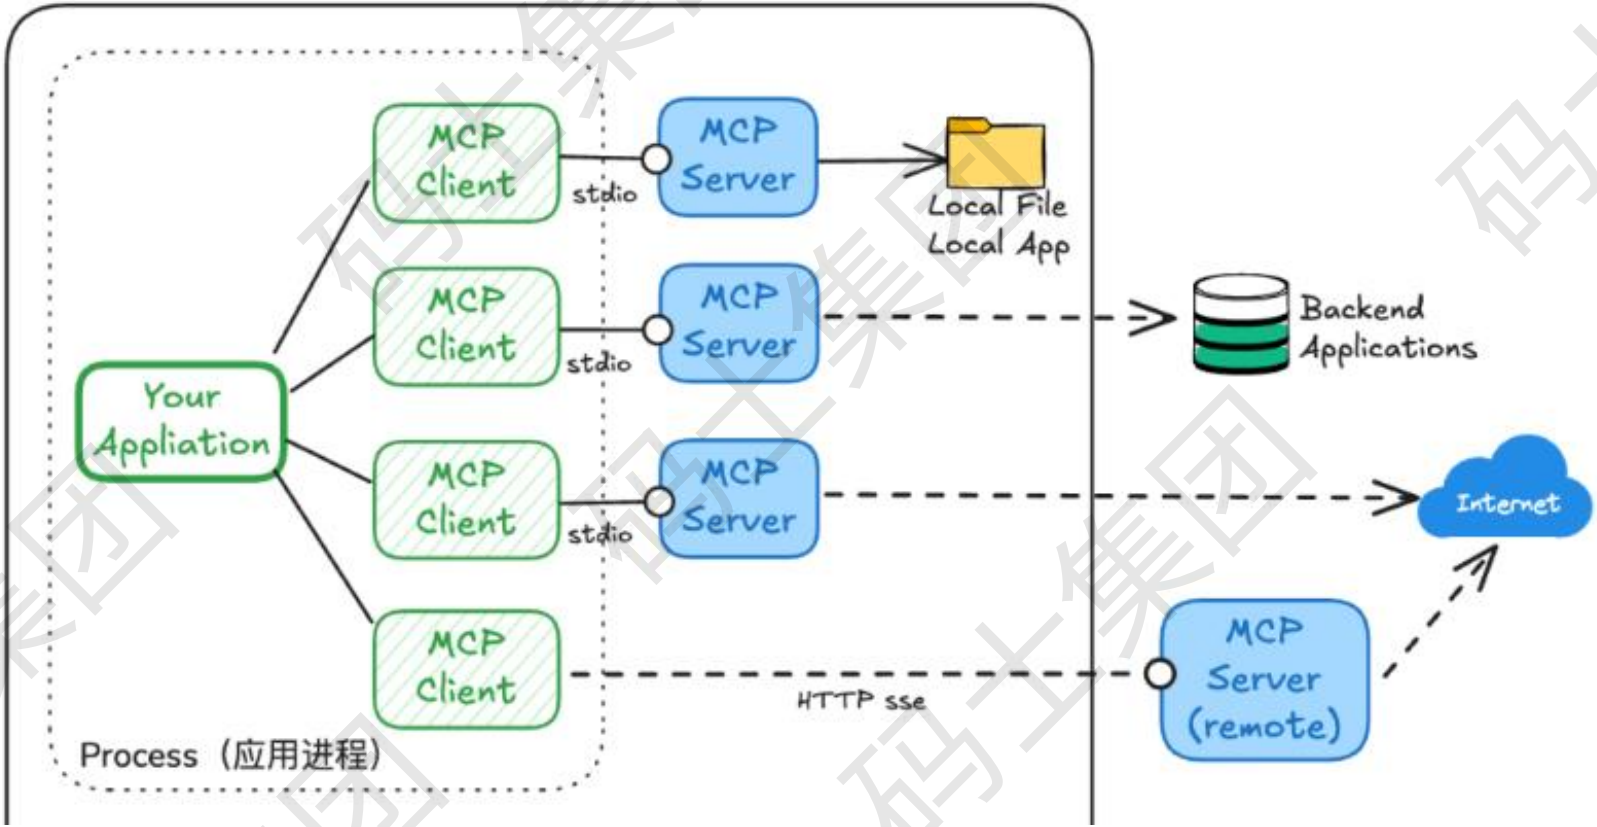

码士集团
www.mashibing.com

什么是上下文工程?

上下文工程是为大模型应用程序精心设计、**管理和提供相关信息（上下文）的实践过程**。其核心目标是：以正确的格式，在正确的时间，向大模型提供恰到好处的信息，使其能够更准确、更可靠地完成特定任务。

- **作用：**存储所有对话的“精华”，供未来会话语义检索。
- **写入时机：**如您所说，在对话结束后，通过多线程异步写入，避免阻塞主流。
- **内容：**存储的可能不是原始对话，而是经过提炼的问答对、关键信息或摘要。
- **检索时机：**在LLM决策为“需要检索”时，将用户问题作为查询向量，在Milvus中进行语义搜索（Similarity Search）。

单Agent和多Agent架构

如果单个智能体需要专精于多个领域或管理许多工具，它可能会出现各种幻觉、准确率降低。为了解决这个问题，您可以将您的智能体分解为更小的、独立的智能体，并将它们组合成一个多智能体系统。

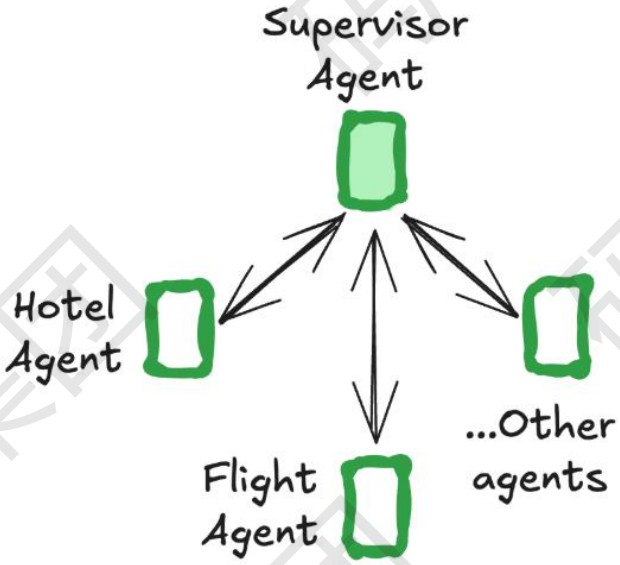

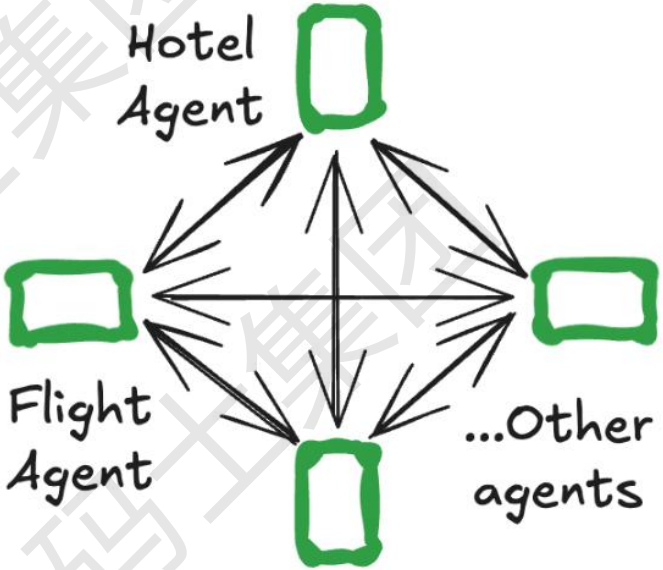

多Agent架构

- 主管（supervisor）—— 各个智能体由一个中央主管智能体协调。主管控制所有的通信流和任务委派，根据当前上下文和任务需求决定调用哪个智能体。
- 群组（swarm）—— 智能体根据各自的专长动态地将控制权移交给彼此。系统会记住最后一个活跃的智能体，以确保在后续交互中，对话能从该智能体恢复。
- Ragas评估多智能体—— 有一个专门的Agent提供最终结果的评估，其他智能体负责具体工作。

- AI大模型大核心开发岗位
  - **大模型应用工程师**
    - 核心职责：使用现成模型/工具，快速结合业务开发应用（Demo、初级产品）
    - 技术特点：重应用、重工具使用、轻底层算法
    - 学历要求：相对较低，本科及以上（非统招也可），更看重项目经验和动手能力
    - 别名：Agent工程师、大模型工程师（需看JD描述）
  - **大模型研发工程师**
    - 核心职责：使用现成模型进行深度应用，包括模型微调、推理优化、构建复杂系统
    - 技术特点：需要理解算法原理和实现，但不深究数学推导
    - 学历要求：本科及以上，计算机相关专业优先
  - **大模型算法工程师**
    - 核心职责：模型预训练、算法研发与优化、发布新模型
    - 技术特点：深入算法数学原理，要求极高的理论基础和创新能力
    - 学历要求：极高，通常要求985/211名校硕士/博士，科班出身，有顶会论文更佳。
    - 招聘企业：极少（全国约10-20家），如字节、阿里、DeepSeek、智谱等

码士集团

AI大模型的体系

你不知道里面的水有多深?

大模型应用工具

- Ollama
- Claude
- Dify
- n8n
- Cursor
- Coze
- RagFlow
- Manus
- SpringAI+Embeddings

大模型应用开发

- 模型的私有化部署
- Agent开发（编程）
- langgraph工作流开发
- RAG+RAGAS开发
- GraphRAG

大模型微调和算法

- 机器学习算法
- Transformer架构
- 深度学习算法
- 大模型微调
- Pytrch框架
- Huggingface
- 大模型强化学习
- 大模型MOE预训练
- 各种微调算法

只能加分

没有对应的岗位

大模型应用工程师 → 大模型工程师+大模型算法工程师

码士集团

码士集团
www.mashibing.com

大模型工程岗位

大模型应用工程师： 明年6~7开始内卷

大模型(开发)工程师 ： 后年4月之后开始内卷
大模型研发工程师

大模型算法工程师： 大模型预训练，算法优化。研究算法。

怎么样才能找到AI大模型工作

项目！项目！还是踏马的项目！

2~ 5小时，那是案例10

码士集团

Tool和Agent

1. Tool（工具）

定义与功能

- **单一功能模块**：`Tool` 是完成特定任务的独立工具，每个工具专注于一项具体操作（如搜索、计算、API调用等）。
- **无决策能力**：工具本身不决定何时被调用，仅在被触发时执行预设操作。
- **输入输出明确**：每个工具需明确定义输入参数和输出格式，例如：
  - **搜索工具**：输入是查询字符串，输出是搜索结果。
  - **计算工具**：输入是数学表达式，输出是计算结果。

MCP+Agent

MCP 协议支持三种主要的通信机制：

1、基于标准输入输出的本地通信（stdio）；
2、基于SSE（Server-Sent Events）的远程通信。是一种基于HTTP协议的单向通信协议，允许服务器以事件流的形式实时向客户端推送数据，而无需客户端明确请求。MCP中的SSE Transport结合了SSE技术和HTTP POST
3、Streamable HTTP是MCP协议推荐的下一代传输机制（3月26日），基于标准HTTP协议实现动态流式升级的传输方式，它移除了专用SSE端点，所有消息通过端点传输，服务器可根据需要将普通HTTP请求升级为SSE流，支持流式响应。

MCP+Agent

HTTP + SSE 的缺陷

远程 `MCP` 通过 `HTTP + SSE` 的传输方式工作，存在以下问题，这也是它所被替换的根本原因：

- 不支持恢复连接
- 要求服务器保持高可用的长连接
- 服务器只能通过 `SSE` 发送消息

不支持恢复连接

如果客户端和服务器之间的 `SSE` 连接中断了，就无法 “从端点继续”，只能重新开始新的连接，之前的上下文可能会丢失。

要求服务器保持高可用的长连接

服务器必须一直保持一个稳定、不中断的 `SSE` 长连接，否则通信就中断。

服务器只能通过 `SSE` 发送消息

服务器无法在已有的请求之外，主动地发送消息给客户端，除了通过专门的 /sse 通道。换句话说，它是 “单向被动响应”，而不是 “任意时机推送”。

码士集团

MCP+Agent

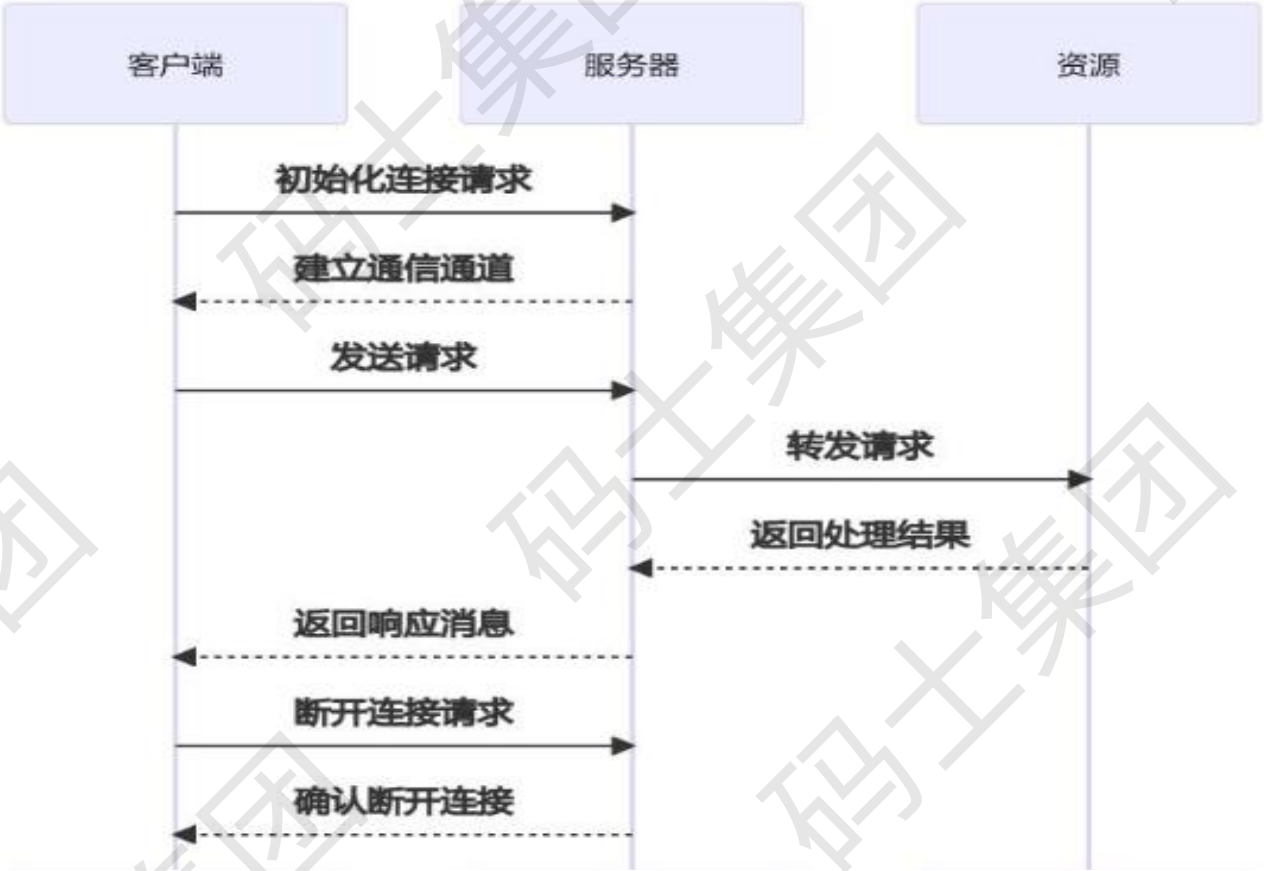
客户端
服务器
资源
初始化连接请求
建立通信通道
发送请求
转发请求
返回处理结果
返回响应消息
断开连接请求
确认断开连接

AI大模型的体系

你不知道里面的水有多深?

大模型应用工具

- Ollama
- Claude
- Dify
- n8n
- Cursor
- Coze
- RagFlow
- Manus

大模型应用开发

- 模型的私有化部署
- Agent开发（编程）
- langgraph工作流开发
- RAG+RAGAS开发
- SpringAI+Embeddings

大模型微调和算法

- 机器学习算法
- Transformer架构
- 深度学习算法
- 大模型微调
- Pytrch框架
- Huggingface
- 大模型强化学习
- 大模型MOE预训练

只能加分

没有对应的岗位

大模型应用工程师 → 大模型工程师+大模型算法工程师

码士集团