码士集团
www.mashibing.com

今晚8:05分正式开始

工业级的AgenticRAG如何优化

1. 传统的RAG和Agentic RAG有什么区别?
2. RAG在哪些地方需要优化?
3. 上下文工程的解决方案?
4. DeepSeek-OCR模型、Embedding模型在RAG中的使用?
5. RAGAS 中评估指标如何影响RAG的正确率?
6. 大模型开发面试过程的变化趋势
7. 大模型开发的简历怎么写?
8. Java或者前端程序可以转AI大模型工程师吗?

讲师：肖斌

码士集团

自我介绍

肖斌

16年从业经验。曾就职于中国电信。

历任高级程序员，数据挖掘师，技术总监等职位；中国电信、中交建集团外聘专家。曾就职于：中国电信。

擅长技术精通Java、Python，Scala三门语言。工作期间主要研究AI大模型和数据挖掘技术，包括：数据结构和算法、ChatGLM模型的调参。Langchain的Agent开发以及和AI大模型的整合。

码士集团 www.mashibing.com

- AI大模型大核心开发岗位
  - 大模型应用工程师
    - 核心职责：使用现成模型/工具，快速结合业务开发应用（Demo、初级产品）
    - 技术特点：重应用、重工具使用、轻底层算法
    - 学历要求：相对较低，本科及以上（非统招也可），更看重项目经验和动手能力
    - 别名：Agent工程师、大模型工程师（需看JD描述）
  - 大模型研发工程师
    - 核心职责：使用现成模型进行深度应用，包括模型微调、推理优化、构建复杂系统
    - 技术特点：需要理解算法原理和实现，但不深究数学推导
    - 学历要求：本科及以上，计算机相关专业优先
  - 大模型算法工程师
    - 核心职责：模型预训练、算法研发与优化、发布新模型
    - 技术特点：深入算法数学原理，要求极高的理论基础和创新能力
    - 学历要求：极高，通常要求985/211名校硕士/博士，科班出身，有顶会论文更佳。
    - 招聘企业：极少（全国约10-20家），如字节、阿里、DeepSeek、智谱等

码士集团

码士集团
www.mashibing.com

什么是Agentic RAG?

RAG + Agents= Agentic RAG。

Agentic RAG 描述了一种基于 AI Agents 的 RAG 实现。具体来说，它将 AI Agents 整合到 RAG 流程中，协调其组件并执行除简单信息检索和生成之外的其他操作，以克服传统 RAG 的局限性。

Agentic RAG将RAG从一个“**信息检索增强工具**”彻底提升为一个“**自主问题解决框架**”。它为RAG注入了“灵魂”，使其能够处理动态、开放式、需要多步推理的复杂现实世界任务，这是之前所有阶段都无法企及的高度。

码士集团

传统的RAG?

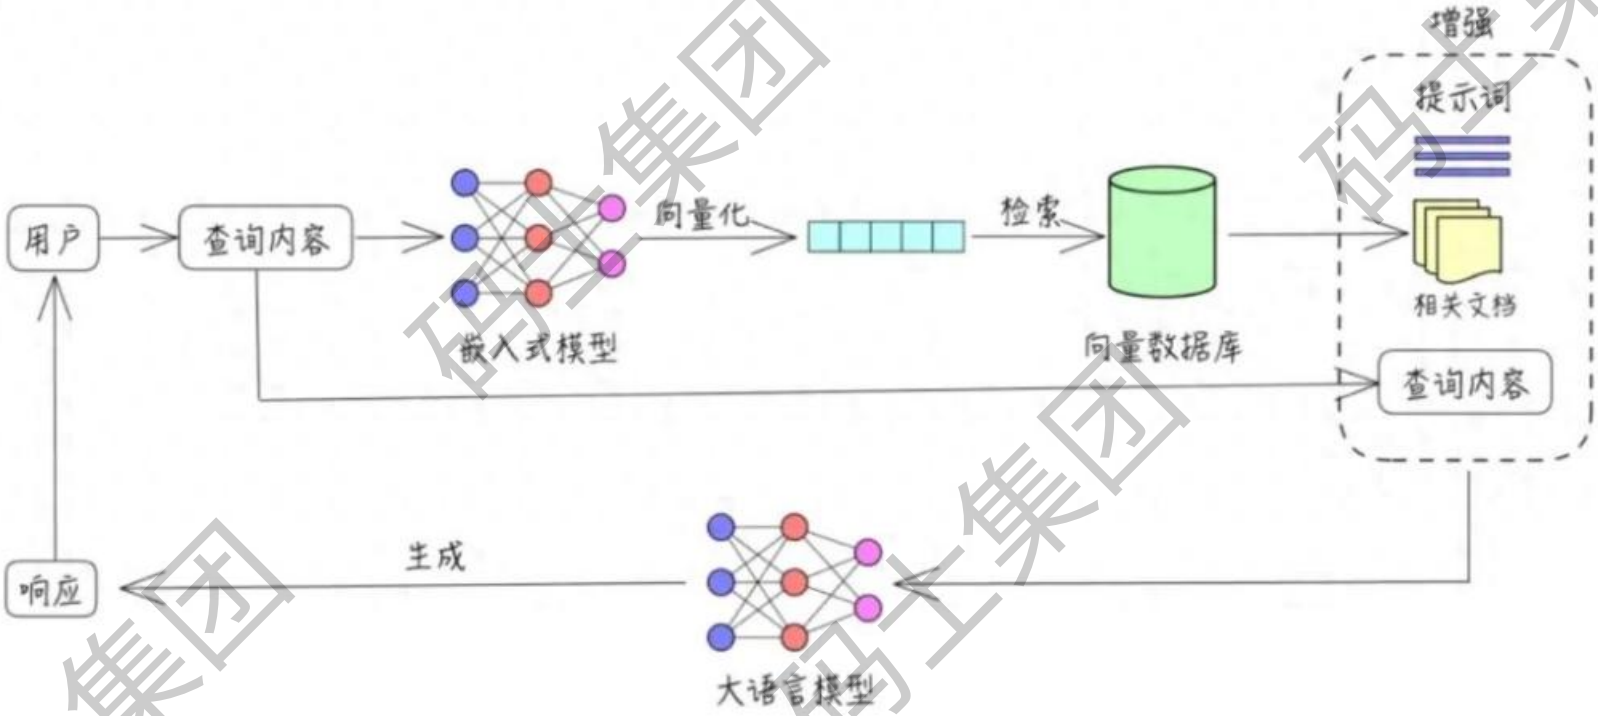

码士集团
www.mashibing.com

什么是Agentic RAG?

- **进化动机**： 为了解决最顶层的挑战——让系统能够像人类一样， **自主地、有策略**地去解决一个复杂问题。
- **核心理念**： “不要给我固定的指令，告诉我你的目标，我自己来制定计划、选择工具、评估结果，甚至寻求同伴的帮助。”
- **关键技术与改进**： 这是RAG思想的一次范式转移，其核心是引入了 AI Agent 。
  - 从“数据流”到“推理环”： 工作流程不再是线性的，而是一个由智能体主导的、循环往复的 “思考-行动-观察” 循环。
  - 自主工具使用 (Autonomous Tool Use)： 智能体在执行计划的每一步，都会自主判断并选择最合适的工具（搜索、计算、API调用等）。
  - 反思与自我评估： 智能体会评估自己每一步的执行结果。它会主动调整计划，重新尝试，例如改写查询词、更换知识库等。
  - 多智能体协作 (Multi-Agent)： 对于极其复杂的任务，系统可以创建一支“智能体团队”，每个智能体扮演不同角色（如研究员、分析师、批评家），它们分工协作，共同完成目标。

码士集团 www.mashibing.com

码士集团
www.mashibing.com

传统RAG

VS

Agentic RAG?

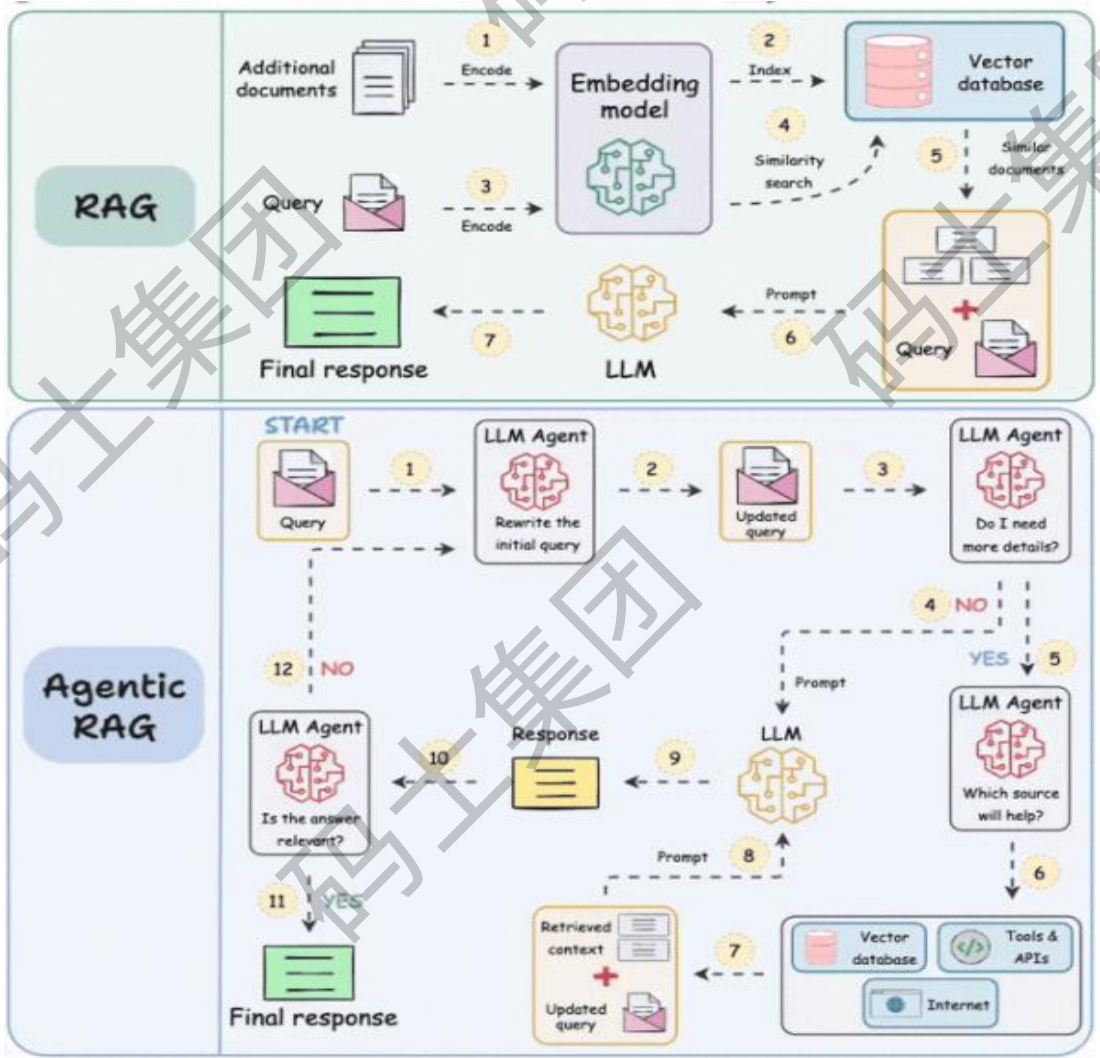

码士集团

提升数据质量 优化

文本切割优化：

- **问题**：简单固定长度的分割会割裂语义（比如把一个句子从中间切断）。
- **优化**：使用更高级的分割策略。
- **递归分割**：先按段落/标题等大边界分割，再对过长部分进行二次分割。
- **语义分割**：利用模型或算法识别语义连贯的单元。

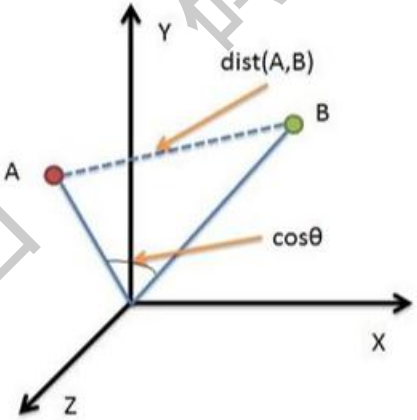

码士集团 www.mashibing.com

提升数据质量 优化

元数据增强 优化：

- **问题**：检索时只依赖纯文本内容，缺乏上下文。
- **优化**：为每个文本块附加丰富的元数据，如：来源文件、章节标题、作者、创建日期、类型等。这些元数据可以用于混合检索或后处理过滤。

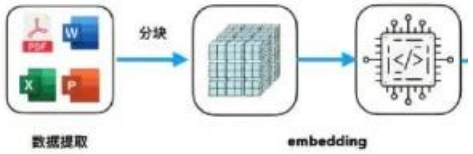

码士集团 www.mashibing.com

提升数据质量 优化

多模态数据 优化:

- **问题**:PDF或者扫描图中有图片，表格，和公式。如何实现Any-To-Any。
- **优化**:采用OCR模型解析多模态内容，并保留关键特征。并且采用多模态嵌入模型实现**多模态向量化**

  - Deepseek.OCR
  - Dots.OCR
  - Dolphin
  - GME-Qwen-VL等等

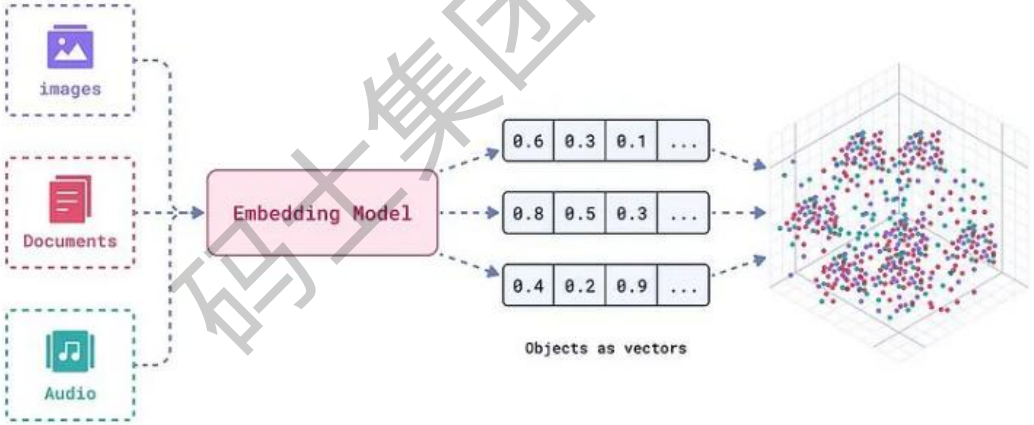

码士集团 www.mashibing.com

码士集团
www.mashibing.com

提升数据索引 优化

数据库索引 优化:

- **问题**:近似近邻搜索算法非常多，如何选择合适的算法和度量来加快搜索速度。
- **优化**:选择AUTOINDEX来选择最合适的密集向量索引，同时给文字内容建立倒排索引提高速度。

  - 使用 MaxScore 算法进行优化的 Document-at-a-Time (DAAT) 查询处理。对于专业术语较多的情况下一定要选择DAAT_MAXSCORE

码士集团

提升搜索质量 优化

混合检索 优化：

- **问题**：单纯基于语义的检索可能忽略关键词匹配的重要性。
- **优化**：结合稀疏检索(如BM25)和稠密检索(嵌入模型)。BM25对精确关键词匹配更有效，两者结果融合可以取长补短。
- **重排**：初步检索返回的Top K个结果中，可能混入一些相关性不高的文档。
- Rerank**模型**：大模型
  - WeightedRanker
  - Qwen3-ReRank模型

码士集团 www.mashibing.com

码士集团
www.mashibing.com

提升搜索质量 优化

检索结果评估 优化：

- **问题**：检索返回的Top K个结果中，可能检索到的质量不佳或者最终大模型生产的答案出现幻觉。
- **优化**：结合RAGAS框架，实现多种指标的评估。

	A	B	C	D
1	指标类别	指标名称	适用场景	评估重点
2	RAG指标	上下文精度	检索精准度	检索结果中相关片段的比例
3	RAG指标	上下文召回率	检索全面性	检索覆盖答案所需信息的比例
4	RAG指标	上下文相关度	检索的相关性	检索结果和用户问题的相关性评估。
5	RAG指标	忠实度	生成内容质量	答案与检索内容的一致性
6	RAG指标	回答相关性	生成内容质量	答案与问题的相关度
7	所有指标	答案准确性	生成答案的准确率	答案与给定问题的参考标准答案之间的一致性

码士集团

提升回答质量和速度 优化

上下文工程 优化:

- **问题**:当上下文内容很长很多时，可能**超出**LLM的上下文窗口，或者关键信息被淹没。当用户的输入问题和历史聊天记录有关时？。
- **优化**：对短期记忆和长期记忆进行管理，并且基于长期记忆进行语义混合检索。

➢ 上下文工程：LLM 失败的原因有以下两个：1、底层 LLM 能力不够；2、“正确”的上下文没有传递给 LLM。

➢ 上下文工程是以正确的格式提供正确的信息和工具，以便 LLM 能够完成任务。这是人工智能工程师的头号工作。

码士集团 www.mashibing.com

最近的笔试和面试有哪些变化

一．数据结构和算法的笔试。
二．Agent问的多，尤其是多Agent架构。
三．评估问的多。
四．切片和向量数据库问的多。
五．上下文工程问的多。
六．Rerank重排会问到。
七．工程化解决方案问的多。
八．应用开发也会问算法，但是停留在了解层面。
九．应用开发也偶尔问Pytorch
一○．研发工程师一定问算法和Pytorch

码士集团 www.mashibing.com

大模型的种类	特点	常用大模型
通用语音模型	通用能力强，文本推理，文本生成，深度思考等	DeepSeek，Qwen3，kimi-k2，GPT-4.5, Claude 3系列，等等
多模态模型	多模态支持（文本/图像/音频/视频），跨媒体理解能力强	GPT-4o，Qwen2.5-VL， Qwen2.5-Omni，GLM-4.5V等
文本嵌入模型	将文本转换成计算机能理解的数值向量，对文本进行降维处理。	BGE系列（small, base, large），OpenAI Embedding，Qwen3-Embedding等
多模态嵌入模型	将文本、图像、音频、视频等不同模态的数据向量化，同一个向量空间中。	GME-Qwen2-VL，openai-CLIP，Chinese-CLIP等
多模态解析模型	负责解析复杂结构的的数据	Dolphin，Dots.OCR，MonkeyOCR，Unstructured等等
垂直领域大模型	专注于某一个领域的复杂问题，如蛋白质结构预测	DeepMind-AlphaFold，360安全大模型，讯飞星火 4.0（医疗）等

码士集团

码士集团
www.mashibing.com

大模型推理框架

推理框架名称	所属团队	核心特点
vLLM	加州大学伯克利分校	高效管理KV缓存，显存利用率可达95%以上；支持张量并行和流水线并行。
SGLang	伯克利团队	利用Radix树高效管理和复用KV缓存前缀，尤其擅长多轮对话；结构化输出，零开销批处理；缓存感知负载均衡
Transformers 库	Hugging Face	提供从模型加载、微调到推理的全流程；灵活的API和训练接口，支持模型范围最广。
LMDeploy	上海人工智能实验室	量化部署工具链，针对华为昇腾等国产芯片优化）、多模态融合支持。
TensorRT-LLM	NVIDIA	深度链路优化，预编译优化，支持FP8/INT4等多种量化方案，内核级优化（针对Transformers模块的深度CUDA优化

码士集团

码士集团
www.mashibing.com

AI大模型能“火”多久?

大模型应用工程师 ： 明年6~7开始内卷

大模型(开发)工程师 ： 后年4月之后开始内卷
大模型研发工程师

大模型算法工程师： 大模型预训练，算法优化。研究算法。

码士集团

码士集团
www.mashibing.com

怎么样才能找到AI大模型工作

项目！项目！还是踏马的项目！

码士集团