码士集团
www.mashibing.com

今晚8:05分正式开始

LangChain-V1+Deep Agent项目

构建工业级的复杂多步骤任务Agent

1. 最新的LangChain-V1.0+MCP解决了什么问题?
2. DeepAgents如何创建复杂Agent
3. SubAgent委派任务并管理上下文
4. 在多Agent架构中完成上下文摘要
5. AI大模型有哪些岗位?
6. AI大模型工程师应该怎么学?
7. AI大模型还能火多久?

讲师：肖斌

自我介绍

肖斌

16年从业经验。曾就职于中国电信。

历任高级程序员，数据挖掘师，技术总监等职位；中国电信、中交建集团外聘专家。曾就职于：中国电信。

擅长技术精通Java、Python，Scala三门语言。工作期间主要研究AI大模型和数据挖掘技术，包括：数据结构和算法、ChatGLM模型的调参。Langchain的Agent开发以及和AI大模型的整合。

LangChain-V1发布

LangChain 于 2022 年 10 月左右由机器学习工程师 Harrison Chase 发起。最初是 Harrison 的一个副业，当时他大约写了 800 行代码，是一个体量不大的单文件 Python 包，于同年秋季发布到了他个人的 GitHub 账户上。
在 2024 年初正式推出LangGraph：允许开发者以更底层的方式编排每一步智能体逻辑。

Harrison 本人曾这样定义："LangChain 是一个构建 LLM 应用程序的框架，但这说法很模糊，也不够具体。我认为部分原因在于 LangChain 的功能实在太丰富了，所以很难用一句话具体说明。"

LangChain-V1发布

Middleware（中间件）：

中间件提供了一种更严格地控制Agent内部发生的事情的方法。中间件在每个步骤之前和之后都可以设置钩子。

- 监控 :通过日志记录、分析和调试跟踪代理行为
- 修改：转换提示、工具选择和输出格式。
- 控制：添加重试、回退和提前终止逻辑。
- 其他：应用速率限制、护栏和 PII 检测

LangChain-V1发布

Guardrails（护栏）：

为您的代理实施安全检查和内容过滤。帮助您构建安全、合规的 AI 应用程序。他们可以检测敏感信息、执行内容策略、验证输出并在不安全行为引起问题之前防止它们。

- 防止 PII 泄漏
- 检测和阻止提示注入攻击
- 屏蔽不当或有害内容
- 执行业务规则和合规性要求
- 验证输出质量和准确性

LangChain-V1发布

上下文工程：

LLM 失败的原因有以下两个：1、底层 LLM 能力不够；2、“正确”的上下文没有传递给 LLM。

上下文工程是以正确的格式提供正确的信息和工具，以便 LLM 能够完成任务。这是人工智能工程师的头号工作。这种缺乏“正确”上下文是更可靠代理的头号障碍，而 LangChain 的代理抽象经过独特设计，以促进上下文工程。

从AIGC到AI Agent

特性	AIGC (如 ChatGPT)	AI Agent (如 Manus, Operator)
核心能力	内容生成	任务规划与自主执行
交互模式	被动响应，依赖**提示词**	主动规划，自主决策
输出结果	建议、方案、内容（需人工后续处理）	**可交付的最终成果**（如已发送的邮件、整理好的报表）
与外界交互	有限，主要通过文本	强大，可通过工具调用操作现实世界系统

2025年是“Agent元年”！从“思考”到“行动”的范式跃迁

什么是 Agent(智能体)

智能体由四个部分组成：大型语言模型（LLM）、一组可供其使用的工具，以及一个提供指令的提示（prompt）和Tool Executor执行器。

Agent是怎么工作的？

LLM 在一个循环中运行。在每次迭代中，它选择一个要调用的工具，提供输入，接收结果（一次观察），并利用该观察来指导下一步行动。这个循环会一直持续，直到满足停止条件——通常是当智能体收集到足够的信息来回应用户时。

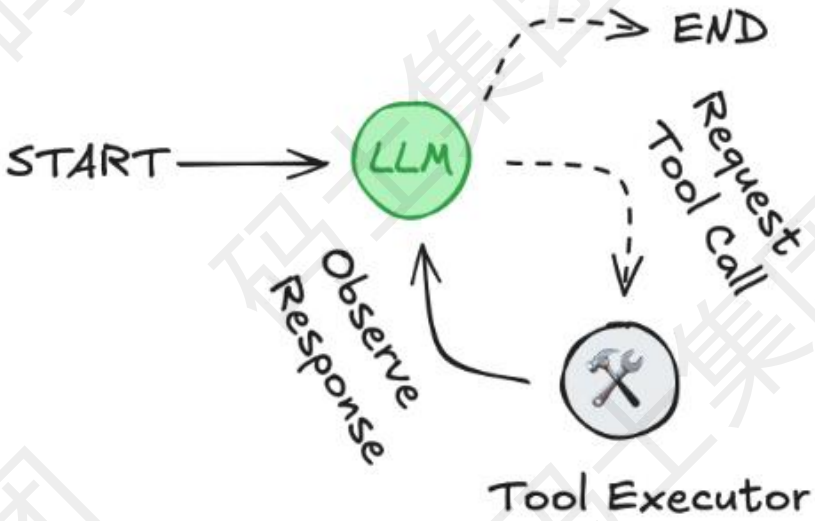

智能体循环：LLM 选择工具并使用其输出来完成用户请求。

码士集团
www.mashibing.com

Agent是怎么工作的？

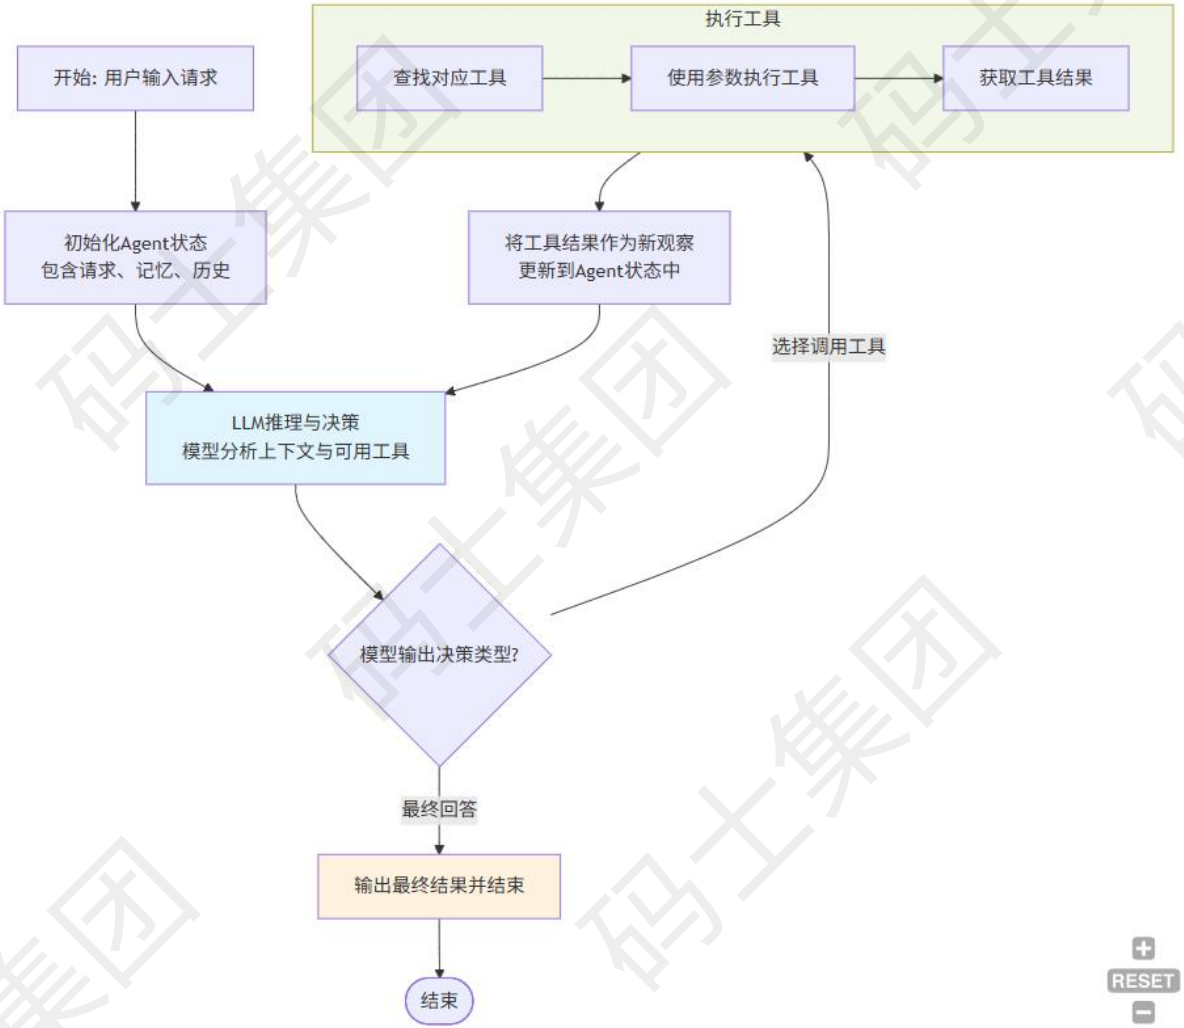

码士集团

码士集团
www.mashibing.com

Agent是怎么工作的？

这个过程通常遵循一种名为 **ReAct (Reason + Act)** 的范式。以下是其工作流程：

步骤 1: 接收输入与构建上下文

Agent接收到用户的请求（例如："上海今天天气怎么样？然后用摄氏度告诉我。"）。执行器会将此请求与之前的对话历史（短期记忆）和任何相关长期记忆组合，形成当前的"上下文"。

步骤 2: LLM 推理与决策

执行器将这个完整的上下文输入给LLM。LLM会根据提示词的指引进行思考。提示词通常会要求模型以特定的格式（如JSON或一段标记清晰的文本）输出它的"想法"和"下一步行动"。

- **Reason (思考)**：模型会先进行内部推理。

> *"用户想知道上海的天气，并且要求用摄氏度表示。我自己没有实时天气数据，所以我需要一个工具来获取这些信息。可用的工具里有一个叫`get_weather`的工具，它可以查询天气。"*

- **Act (行动)**：然后，模型会根据思考结果，决定一个行动。这个行动要么是**最终回答**，要么是**调用一个工具**。

> "我应该调用`get_weather`工具，参数是location='上海'。"

工业级的Agent应该掌握什么？

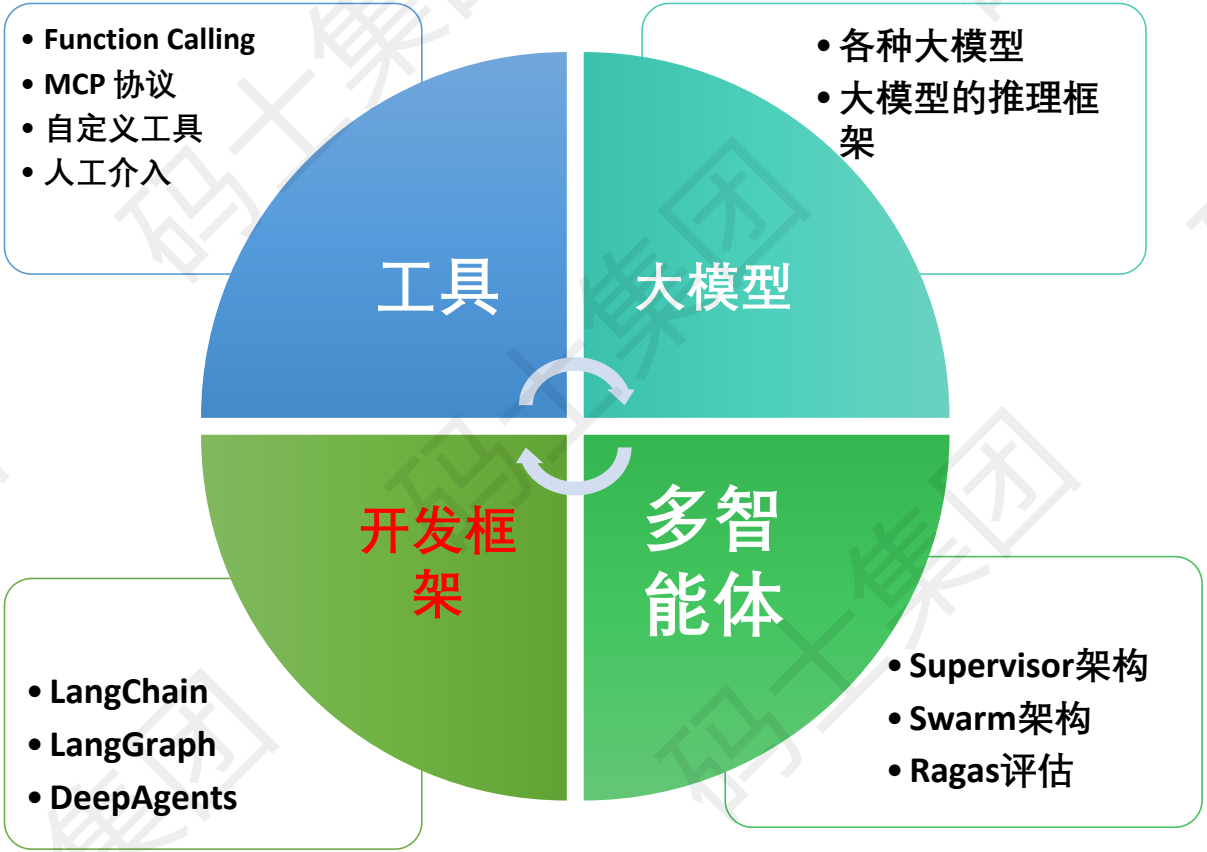

MCP+Agent

MCP（Model Context Protocol，模型上下文协议），2024年11月底，由 Anthropic 推出的一种开放标准，旨在统一大型语言模型（LLM）与外部数据源和工具之间的通信协议。

Function Calling是AI模型调用函数的机制，MCP是一个标准协议，使AI模型与API无缝交互，而AI Agent是一个自主运行的智能系统，利用Function Calling和MCP来分析和执行任务，实现特定目标。

MCP+Agent

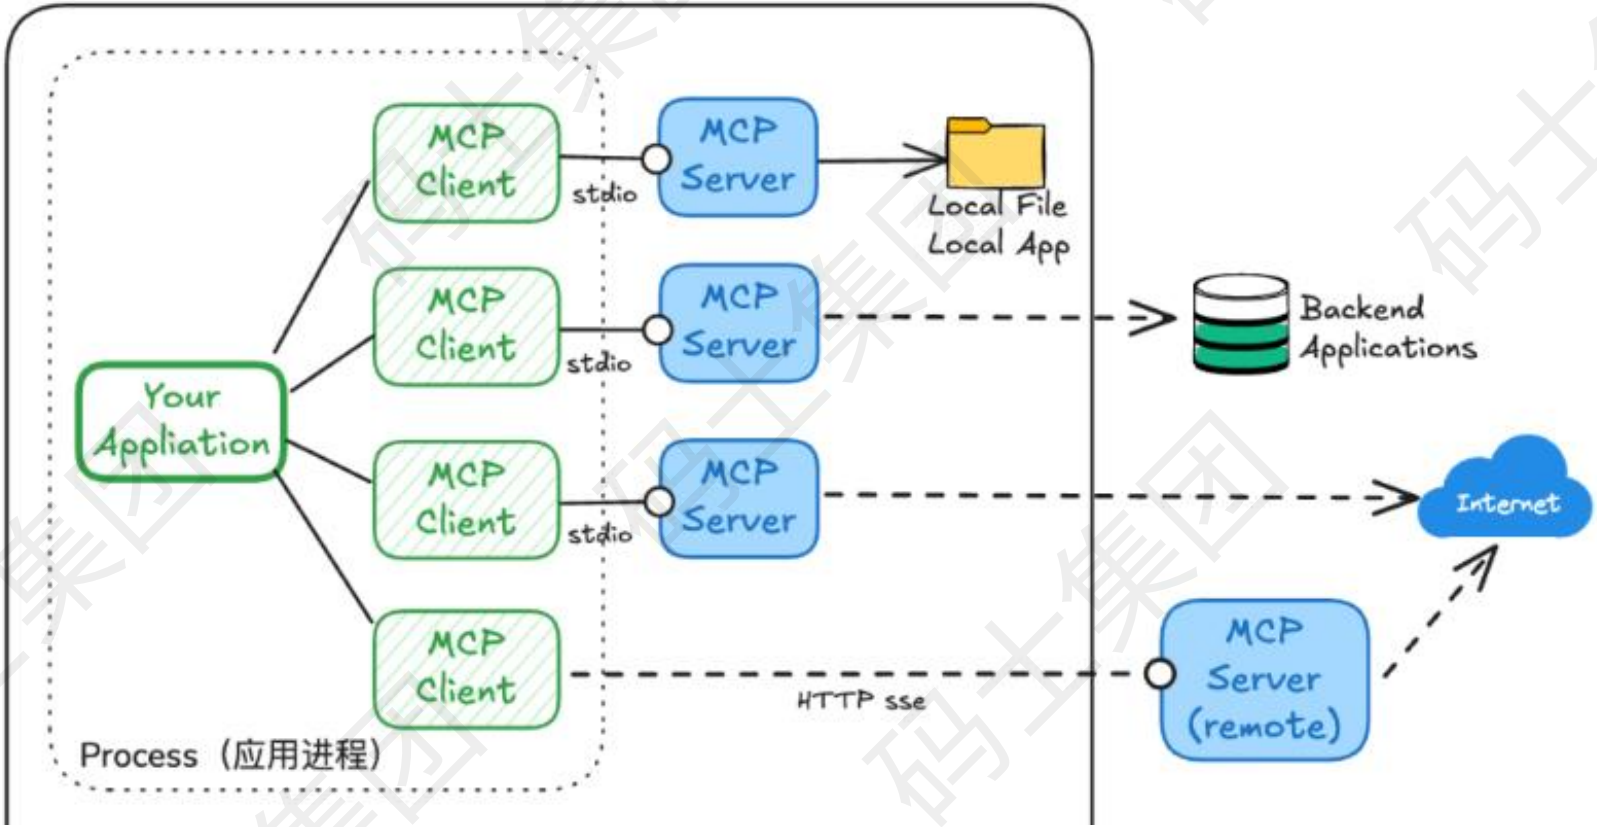
MCP Client
stdio
MCP Server
Local File
Local App
MCP Client
stdio
MCP Server
Backend Applications
Your Appliation
MCP Client
stdio
MCP Server
Internet
MCP Client
HTTP sse
MCP Server (remote)
Process（应用进程）

Deep Agents

DeepAgents 是一个独立的库，可以利用文件系统，用于构建能够处理复杂、多步骤任务的智能体。Deep Agents 基于 LangGraph 构建，并受到 Claude Code、Deep Research 和 Manus 等应用程序的启发，具有规划能力、用于上下文管理的文件系统以及生成子agent的能力。

```python
class SubAgent(TypedDict):
    name: str
    description: str
    prompt: str
    tools: Sequence[BaseTool | Callable | dict[str, Any]]
    model: NotRequired[str | BaseChatModel]
    middleware: NotRequired[list[AgentMiddleware]]
    interrupt_on: NotRequired[dict[str, bool | InterruptOnConfig]]

class CompiledSubAgent(TypedDict):
    name: str
    description: str
    runnable: Runnable
```

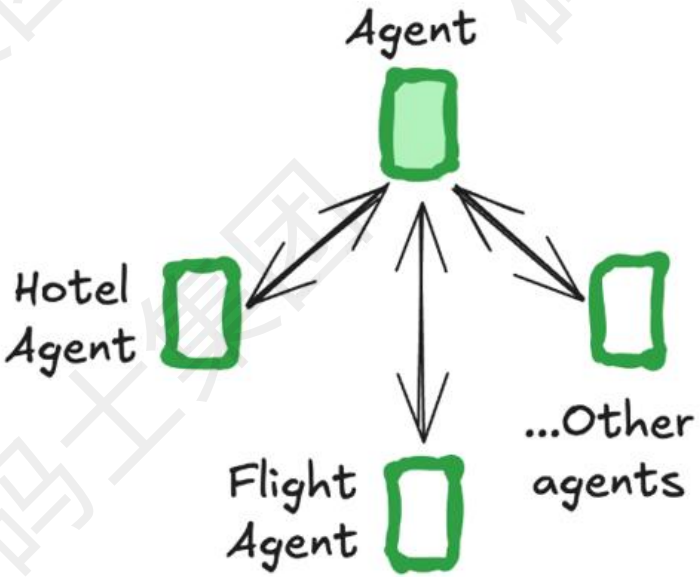

AI大模型大核心开发岗位

- **大模型应用工程师**
  - 核心职责：使用现成模型/工具，快速结合业务开发应用（Demo、初级产品）
  - 技术特点：重应用、重工具使用、轻底层算法
  - 学历要求：相对较低，本科及以上（非统招也可），更看重项目经验和动手能力
  - 别名：Agent工程师、大模型工程师（需看JD描述）
- **大模型研发工程师**
  - 核心职责：使用现成模型进行深度应用，包括模型微调、推理优化、构建复杂系统
  - 技术特点：需要理解算法原理和实现，但不深究数学推导
  - 学历要求：本科及以上，计算机相关专业优先
- **大模型算法工程师**
  - 核心职责：模型预训练、算法研发与优化、发布新模型
  - 技术特点：深入算法数学原理，要求极高的理论基础和创新能力
  - 学历要求：极高，通常要求985/211名校硕士/博士，科班出身，有顶会论文更佳。
  - 招聘企业：极少（全国约10-20家），如字节、阿里、DeepSeek、智谱等

码士集团

AI大模型的体系

你不知道里面的水有多深?

大模型应用工具

- Ollama
- Trace
- Dify
- n8n
- Cursor
- Coze
- RagFlow
- Manus
- LLaMA-Factory
- SpringAI+数字人

大模型应用开发

- 模型的私有化部署
- Agent开发（编程）
- langgraph工作流开发
- RAG,+RAG,AS开发
- GraphRAG

- 大语言推理模型
- 多模态大模型
- 各种嵌入模型
- 多模态解析模型
- VLLM, SGlang, Transformers

大模型微调和算法

- 机器学习算法
- Transformer架构
- 深度学习算法
- 大模型微调，量化，蒸馏
- Pytrch框架
- Huggingface
- 大模型强化学习
- 大模型MOE预训练
- 各种微调算法

各种数据库

- Postgre-SQL
- Milvus
- Neo4J
- Redis
- Chroma
- FAISS
- ES

- 多智能体综合项目
- 多模态AgenticRAG项目
- 多模态微调项目
- MoE全参数微调项目
- GUI-Agent项目

码士集团

大模型的种类	特点	常用大模型
通用语音模型	通用能力强，文本推理，文本生成，深度思考等	DeepSeek，Qwen3，kimi-k2，GPT-4.5, Claude 3系列，等等
多模态模型	多模态支持（文本/图像/音频/视频），跨媒体理解能力强	GPT-4o，Qwen2.5-VL， Qwen2.5-Omni，GLM-4.5V等
文本嵌入模型	将文本转换成计算机能理解的数值向量，对文本进行降维处理。	BGE系列（small, base, large），OpenAI Embedding，Qwen3-Embedding等
多模态嵌入模型	将文本、图像、音频、视频等不同模态的数据向量化，同一个向量空间中。	GME-Qwen2-VL，openai-CLIP，Chinese-CLIP等
多模态解析模型	负责解析复杂结构的的数据	Dolphin，Dots.OCR，MonkeyOCR，Unstructured等等
垂直领域大模型	专注于某一个领域的复杂问题，如蛋白质结构预测	DeepMind-AlphaFold，360安全大模型，讯飞星火 4.0（医疗）等

码士集团

码士集团
www.mashibing.com

大模型推理框架

推理框架名称	所属团队	核心特点
vLLM	加州大学伯克利分校	高效管理KV缓存，显存利用率可达95%以上；支持张量并行和流水线并行。
SGLang	伯克利团队	利用Radix树高效管理和复用KV缓存前缀，尤其擅长多轮对话；结构化输出，零开销批处理；缓存感知负载均衡
Transformers 库	Hugging Face	提供从模型加载、微调到推理的全流程；灵活的API和训练接口，支持模型范围最广。
LMDeploy	上海人工智能实验室	量化部署工具链，针对华为昇腾等国产芯片优化）、多模态融合支持。
TensorRT-LLM	NVIDIA	深度链路优化，预编译优化，支持FP8/INT4等多种量化方案，内核级优化（针对Transformers模块的深度CUDA优化

码士集团
www.mashibing.com

AI大模型能“火”多久?

大模型应用工程师： 明年6~7开始内卷

大模型(开发)工程师 ： 后年4月之后开始内卷
大模型研发工程师

大模型算法工程师：大模型预训练，算法优化。研究算法。

怎么样才能找到AI大模型工作

项目！项目！还是踏马的项目！

码士集团

码士
www.mas

10:48

vip

10:30

姐，我这边有个岗位做AO系统的需要Java希望懂一点AI要不咱们内推一个

我拍了拍

OA打错了

国企正式工年薪18-25W

觉得还行，目前Java的行情，这工资还可以了

5"

35岁以下

我们应该有学员是之前干Java的现在来学ai的，这种应该就比较符合

按住 说话

东方国信徐先生

2025年5月20日 19:02

你已添加了轻舟，现在可以开始聊天了。

你好🤝，请推荐懂MCP和大模型开发的工程师，可短期或长期

东方国信

2025年5月20日 19:26

好的

我现在在家里，我现在正联系我们的另外两个老师，明天应该有消息。

嗯嗯

2025年5月21日 20:33

你好，问一下，去哪里上班哪个城市？

发送(S)

码士集团

@微信

就是即将入职的公司打电话过来问我简历上之前的工作经历

学
学

那谢谢了🍌

我刚刚通过了一

25.5.13 -MCA套+大模型

报名时间：2025-5-13
姓名及年龄：&40
学校及学历：西安工程大学&工商管理
目前学到的技能栈：Java技术栈，Spring体系，Spring Cloud，Redis,Mongo,Kafka,RabbitMQ,XXL-Job
目前薪资及地点：17K，西安
短期诉求：（提升或换工作或其他）目前离职，希望尽快找到工作，回归正常工作
跳槽时间安排，期望薪资及地点：期望17k-20k，西安
报名课程原因：提升技术储备，提高面试成功率，长期职业规划辅导
自我评估： 7年Java编程研发设计经验(其中包含2年系统架构设计和带领技术团队相关经验)，华为/大众车载项目诊断系统2年SE经验(对接海外客户，软硬结合　业务需求分析和技术方案设计)，荣耀PC产品1年软件特性SE经验(业务需求分析和系统方案设计)。
痛点: 每天投简历，每隔1到2周都有面试，但总是面试失败，分析原因是技术积累不够，对常用技术逻辑不是很清晰。

25.5.13 -MCA套+大模型

小叶
群主

06月03日 20:33

目前有两个Offer，一个是农发行项目，一个是汇丰项目，需要老师们帮我参考一下如何决策，选哪个对我最有利。

安小琦

哇先恭喜一下可以把这两个公司的情况 福利待遇发一下呢

农发行项目，业务是智能工具，银行内部作业中心改造，微服务架构，薪资

40 岁西安大龄程序员，2 月份离职，空窗 3 个月，报名之前，虽每周都有面试，但都失败了，报名 MCA 系列+大模型课程 20 天后，拿到了两家 offer

码士集团

25.5.13 -MCA套+大模型

报名时间：2025-5-13
姓名及年龄：&40
学校及学历：西安工程大学&工商管理
目前学到的技能栈：Java技术栈，Spring体系，Spring Cloud，Redis,Mongo,Kafka,RabbitMQ,XXL-Job
目前薪资及地点：17K，西安
短期诉求：（提升或换工作或其他）目前离职，希望尽快找到工作，回归正常工作
跳槽时间安排，期望薪资及地点：期望17k-20k，西安
报名课程原因：提升技术储备，提高面试成功率，长期职业规划辅导
自我评估： 7年Java编程研发设计经验(其中包含2年系统架构设计和带领技术团队相关经验)，华为/大众车载项目诊断系统2年SE经验(对接海外客户，软硬结合 业务需求分析和技术方案设计)，荣耀PC产品1年软件特性SE经验(业务需求分析和系统方案设计)。
痛点: 每天投简历，每隔1到2周都有面试，但总是面试失败，分析原因是技术积累不够，对常用技术逻辑不是很清晰。

25.5.13 -MCA套+大模型

小叶
群主

06月03日 20:33

目前有两个Offer，一个是农发行项目，一个是汇丰项目，需要老师们帮我参考一下如何决策，选哪个对我最有利。

安小琦

哇先恭喜一下可以把这两个公司的情况 福利待遇发一下呢

农发行项目，业务是智能工具，银行内部作业中心改造，微服务架构，薪资

40 岁西安大龄程序员，2 月份离职，空窗 3 个月，报名之前，虽每周都有面试，但都失败了，报名 MCA 系列+大模型课程 20 天后，拿到了两家 offer